



INF-493. MACHINE LEARNING. TAREA 1.

MÉTODOS LINEALES PARA REGRESIÓN

Prof. Ricardo Ñanculef & Carlos Valle
jnancu@inf.utfsm.cl - cvalle@inf.utfsm.cl

Temas

- Manipulación de dataframes en *pandas*.
- Estandarización y normalización de datos.
- Manipulación básica de matrices en *numpy*.
- Regresión lineal multivariada usando *sklearn*.
- Selección de atributos, *from scratch*.
- Regularización (Ridge regression, Lasso) usando *sklearn*.
- Validación cruzada (cross-validation) usando *sklearn*.

Formalidades

- Equipos de trabajo de: 2 personas.*.
- Se debe preparar un (breve) Jupyter/IPython notebook que explique la actividad realizada y las conclusiones del trabajo.
- En la clase del Viernes 13 de Octubre, el grupo (todos los integrantes) debe venir preparado para presentar cada punto de la tarea. Puede utilizar Jupiter, diapositivas, o cualquier material de apoyo.
- Se debe mantener un respaldo de cualquier tipo de código utilizado, informe y presentación en Github.
- Deadline: Viernes 13 de Octubre a las 22:00hrs.
- Formato de entrega: envío de link Github al correo electrónico del ayudante incluyendo a todos los profesores en copia y especificando asunto: [TallerXXX-CursoXXX-Semestre-Año].

*La modalidad de trabajo en equipo nos parece importante, porque en base a nuestra experiencia enriquece significativamente la experiencia de aprendizaje. Sin embargo, esperamos que esto no se transforme en una cruda división de tareas. Cada miembro del equipo debe estar en condiciones de realizar una presentación y discutir sobre cada punto del trabajo realizado.

1 Regresión Lineal Ordinaria (LSS)

En esta sección trabajaremos con un dataset conocido como *House Sales in King County, USA*, este se encuentra en Kaggle [1] y contiene los precios en el que se vendieron distintas casas en los Estados Unidos entre Mayo del 2014 y Mayo del 2015. Las casas tienen distintas características que vienen descritas en el dataset, como la cantidad de habitaciones, cantidad de baños, número de pisos, ubicación geográfica, etc. La variable que nos interesará predecir a partir de los demás atributos será el precio de las casas.

- (a) Construya un dataframe con los datos a analizar descargando los datos desde la URL adjunta.

```
1 import pandas as pd
2 import numpy as np
3 df = pd.read_csv("kc_house_data.csv", sep = ",", header = 0)
4 df = df.drop(['id', 'date', 'zipcode'], axis=1)
```

- (b) Describa brevemente el dataset utilizar.

```
1 df.shape
2 df.info()
3 df.describe()
```

- (c) Normalice los datos antes de trabajar. Explique la importancia/conveniencia de realizar esta operación.

```
1 from sklearn.preprocessing import StandardScaler
2 scaler = StandardScaler()
3 df_scaled = pd.DataFrame(scaler.fit_transform(df), columns=df.columns)
4 df_scaled['price'] = np.log(df['price'])
```

- (d) Realice una regresión lineal de mínimos cuadrados básica. Explique la importancia/conveniencia del paso 4 y los argumentos que se deben entregar a la función que implementa la regresión lineal.

```
1 import sklearn.linear_model as lm
2 X = df_scaled.iloc[:,1:]
3 N = X.shape[0]
4 X.insert(X.shape[1], 'intercept', np.ones(N))
5 y = df_scaled['price']
6 mask = np.zeros(len(X))
7 limit = int(len(X)*0.7)
8 mask[:limit] = 1
9 istrain = mask== 1
10 Xtrain = X[istrain]
11 ytrain = y[istrain]
12 Xtest = X[np.logical_not(istrain)]
13 ytest = y[np.logical_not(istrain)]
14 linreg = lm.LinearRegression(fit_intercept = False)
15 linreg.fit(Xtrain, ytrain)
```

- (e) Construya una tabla con los pesos y Z-score correspondientes a cada predictor (variable). ¿Observa algún problema? Si es así, comente y proponga un metodo para eliminar dicho problema.

```
# do it yourself :-)
```

- (f) Estime el error de predicción del modelo usando validación cruzada con un número de “folds” igual a $K = 5$ y $K = 10$. Recuerde que para que la estimación sea razonable debe ajustar los pesos del modelo de nuevo, cada vez que trabaja sobre un determinado “fold”. Mida el error real del modelo sobre el conjunto de pruebas, compare y concluya.

```

1 yhat_test = linreg.predict(Xtest)
2 mse_test = np.mean(np.power(yhat_test - ytest, 2))
3 from sklearn.model_selection import KFold
4 Xm = Xtrain.as_matrix()
5 ym = ytrain.as_matrix()
6 kf = KFold(n_splits=10)
7 mse_cv = 0
8 for train, val in kf.split(Xm):
9     linreg = lm.LinearRegression(fit_intercept = False)
10    linreg.fit(Xm[train], ym[train])
11    yhat_val = linreg.predict(Xm[val])
12    mse_fold = np.mean(np.power(yhat_val - ym[val], 2))
13    mse_cv += mse_fold
14 mse_cv = mse_cv / 10

```

- (j) Mida los errores de predicción para cada dato de entrenamiento. Utilizando un “quantile-quantile plot” determine si es razonable la hipótesis de normalidad sobre los residuos del modelo.
- (h) Se generan dos muestreos de datos donde el valor de sus etiqueta siguen distribuciones distintas: Genere dos modelos, evalúe y compare sus comportamientos.

```

1 df_A = df_scaled.sample(3000)
2 frames = []
3 valor = df_scaled.price
4 for z in np.arange(int(np.min(valor)),int(np.max(valor))+1,0.5):
5     frames.append(df_scaled[(df_scaled.price >= z) & (df_scaled.price < z+0.5)].head(500))
6 df_B = pd.concat(frames).sample(3000)
7 X_A = df_A.iloc[:,1:].values
8 y_A = np.log(df_A.price)
9 X_B = df_B.iloc[:,1:].values
10 y_B = np.log(df_B.price)
11 from sklearn.model_selection import train_test_split
12 Xtrain_A, Xval_A, ytrain_A, yval_A = train_test_split(X_A, y_A, test_size=0.3, random_state=42)
13 Xtrain_B, Xval_B, ytrain_B, yval_B = train_test_split(X_B, y_B, test_size=0.3, random_state=42)

```

2 Selección de Atributos

Utilizando el dataframe de la actividad anterior,

- (a) Construya una función que implemente Forward Step-wise Selection (FSS). Es decir, partiendo con un modelo sin predictores (variables), agregue un predictor a la vez, re-ajustando el modelo de regresión en cada paso. Para seleccionar localmente una variable, proponga/implemente un criterio distinto al utilizado en el código de ejemplo. Construya un gráfico que muestre el error de entrenamiento y el error de pruebas como función del número de variables en el modelo. Ordene el eje x de menor a mayor.

```

1 def fss(x, y, names_x, k = 10000):
2     p = x.shape[1]-1
3     k = min(p, k)
4     names_x = np.array(names_x)
5     remaining = range(0, p)
6     selected = [p]
7     current_score = 0.0
8     best_new_score = 0.0
9     while remaining and len(selected)<=k :
10         score_candidates = []

```

```

11         for candidate in remaining:
12             model = lm.LinearRegression(fit_intercept=False)
13             indexes = selected + [candidate]
14             x_train = x[:, indexes]
15             predictions_train = model.fit(x_train, y).predict(x_train)
16             residuals_train = predictions_train - y
17             mse_candidate = np.mean(np.power(residuals_train, 2))
18             score_candidates.append((mse_candidate, candidate))
19         score_candidates.sort()
20         score_candidates[:] = score_candidates[::-1]
21         best_new_score, best_candidate = score_candidates.pop()
22         remaining.remove(best_candidate)
23         selected.append(best_candidate)
24         print "selected = %s ..." % names_x[best_candidate]
25         print "totalvars=%d, mse = %f" % (len(indexes), best_new_score)
26     return selected
27
28     '''Revise si la cantidad de etiquetas concuerda con la cantidad de variables que esta utilizando,
29     puede que tenga que eliminar un elemento de la lista name_regressors'''
30
31     names_regressors = ["bedrooms", "bathrooms", "sqft_living", "sqft_lot", "floors", "waterfront", "view",
32     "condition", "grade", "sqft_above", "sqft_basement", "yr_built", "yr_renovated", "lat-long",
33     "sqft_living15", "sqft_lot15", "intercept"]
34     fss(Xm, ym, names_regressors)

```

3 Regularización

Utilizando el dataframe de la actividad anterior,

- (a) Ajuste un modelo lineal utilizando “Ridge Regression”, es decir, regularizando con la norma ℓ_2 . Utilice valores del parámetro de regularización λ^\dagger en el rango $[10^4, 10^{-1}]$. Construya un gráfico que muestre los coeficientes obtenidos como función del parámetro de regularización. Describa lo que observa. (**Hint:** Note que la línea 4 y el primer argumento en la línea 12 son críticos).

```

1  from sklearn.linear_model import Ridge
2  import matplotlib.pyplot as plt
3  X_c = X.copy()
4  X_c = X_c.drop('intercept', axis=1)
5  Xtrain = X_c[istrain]
6  ytrain = y[istrain]
7  names_regressors = ["bedrooms", "bathrooms", "sqft_living", "sqft_lot", "floors", "waterfront", "view",
8  "condition", "grade", "sqft_above", "sqft_basement", "yr_built", "yr_renovated", "lat-long",
9  "sqft_living15", "sqft_lot15"]
10 alphas_ = np.logspace(4, -1, base=10)
11 coefs = []
12 model = Ridge(fit_intercept=True, solver='svd')
13 for a in alphas_:
14     model.set_params(alpha=a)
15     model.fit(Xtrain, ytrain)
16     coefs.append(model.coef_)
17 ax = plt.gca()
18 for y_arr, label in zip(np.squeeze(coefs).T, names_regressors):
19     print alphas_.shape

```

[†]Se asume la siguiente formulación: $\min_w \|Y - Xw\|^2 + \lambda \|w\|^2$.

```

20         print y_arr.shape
21         plt.plot(alphas_, y_arr, label=label)
22     plt.legend()
23     ax.set_xscale('log')
24     ax.set_xlim(ax.get_xlim()[::-1]) # reverse axis
25     plt.xlabel('alpha')
26     plt.ylabel('weights')
27     plt.title('Regularization Path RIDGE')
28     plt.axis('tight')
29     plt.legend(loc=2)
30     plt.show()

```

- (b) Ajuste un modelo lineal utilizando el método “Lasso”, es decir, regularizando con la norma ℓ_1 . Utilice valores del parámetro de regularización λ^s en el rango $[10^1, 10^{-2}]$. Para obtener el código, modifique las líneas 7 y 9 del ejemplo anterior. Construya un gráfico que muestre los coeficientes obtenidos como función del parámetro de regularización. Describa lo que observa. ¿Es más efectivo Lasso para seleccionar atributos?

```

1  from sklearn.linear_model import Lasso
2  alphas_ = np.logspace(0,-3,base=10)
3  clf = Lasso(fit_intercept=True)

```

- (c) Utilizando “Ridge Regression”, construya un gráfico que muestre el error de entrenamiento y el error de pruebas como función del parámetro de regularización. Discuta lo que observa.

```

1  {\tiny Xtest = X[np.logical_not(istrain)]
2  ytest = y[np.logical_not(istrain)]
3  Xtest = Xtest.drop('intercept', axis=1)
4  alphas_ = np.logspace(4,-2,base=10)
5  coefs = []
6  model = Ridge(fit_intercept=True)
7  mse_test = []
8  mse_train = []
9  for a in alphas_:
10     model.set_params(alpha=a)
11     model.fit(Xtrain, ytrain)
12     yhat_train = model.predict(Xtrain)
13     yhat_test = model.predict(Xtest)
14     mse_train.append(np.mean(np.power(yhat_train - ytrain, 2)))
15     mse_test.append(np.mean(np.power(yhat_test - ytest, 2)))
16  ax = plt.gca()
17  ax.plot(alphas_,mse_train,label='train error ridge')
18  ax.plot(alphas_,mse_test,label='test error ridge')
19  plt.legend(loc=2)
20  ax.set_xscale('log')
21  ax.set_xlim(ax.get_xlim()[::-1])
22  plt.show()}

```

- (d) Utilizando “Lasso”, construya un gráfico que muestre el error de entrenamiento y el error de pruebas como función del parámetro de regularización. Discuta lo que observa.

```

1  alphas_ = np.logspace(0.5,-2,base=10)

```

- (e) Estime el valor del parámetro de regularización en los métodos anteriores usando validación cruzada.

^sSe asume la siguiente formulación: $\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|^2 + \lambda \|\mathbf{w}\|_{\ell_1}$.

```

1 MSE = lambda y,yhat: np.mean(np.power(y-yhat,2))
2 Xm = Xtrain.as_matrix()
3 ym = ytrain.as_matrix()
4 from sklearn import cross_validation
5 k_fold = cross_validation.KFold(len(Xm),10)
6 best_cv_mse = float("inf")
7 model = Lasso(fit_intercept=True)
8 for a in alphas_:
9     model.set_params(alpha=a)
10    mse_list_k10 = [MSE(model.fit(Xm[train], ym[train]).predict(Xm[val]), ym[val]) \
11                    for train, val in k_fold]
12    if np.mean(mse_list_k10) < best_cv_mse:
13        best_cv_mse = np.mean(mse_list_k10)
14        best_alpha = a
15    print "BEST PARAMETER=%f, MSE(CV)=%f"%(best_alpha,best_cv_mse)

```

4 Predicción de Utilidades de Películas

El problema a resolver en esta sección consiste en predecir el volumen de utilidades (en dólares) obtenidas por el estreno (al público, en USA) de una película. Específicamente consideraremos dos posibles respuestas: el volumen total de utilidades (total revenue) obtenido durante el fin de semana del estreno y el volumen de utilidades por lugar de proyección (per screen revenue). Los datos a utilizar fueron recolectados en un estudio publicado recientemente por M. Joshi y colegas de la universidad de Carnegie Mellon [3], y corresponden a 1718 películas realizadas entre 2005 y 2009. Cada película, se representa utilizando diversos tipos de atributos

1. Texto: A partir de las críticas publicadas para cada película (en diversos sitios y antes del estreno), se construyen características que corresponden a la frecuencia de palabras, parejas de palabras y tríos de palabras obtenidas de un vocabulario.
2. Metadata: (1) Variable binaria que indica si el lugar de origen de la película es USA, (2) logaritmo del presupuesto, (3) número de puntos de proyección, (4) género (acción, drama, comedia, etc), (5) Calificación de la MPAA (mayores de catorce, todo espectador, etc), (6) Variable binaria que indica si el estreno se produjo durante un feriado/vacaciones y (7) Número de actores con OSCAR.

Los datos pueden ser descargados ejecutando los siguientes comandos en un terminal (sistemas UNIX)

```

1 wget http://www.inf.utfsml.cl/~cvalle/movies.tar.gz
2 tar -xzf movies.tar.gz
3 rm movies.tar.gz

```

Para facilitar el trabajo, los datos han sido ya preparados en formato matricial. Concretamente usted dispondrá de tres parejas de archivos (X e y): un conjunto de datos de entrenamiento (*train.x.nm* y *train.y.dat*), un conjunto de datos de validación para evitar tener que hacer validación cruzada (*dev.x.nm* y *dev.y.dat*) y un conjunto de datos de pruebas (*test.x.nm* y *test.y.dat*) que, naturalmente, no puede utilizar para construir el modelo. Se incluirán además, dos versiones de los datos. Una de ellas consiste en remover la variable que indica la presencia de actores con OSCAR del conjunto de atributos.

El archivo de respuestas (y) contiene un dato por fila en el orden correspondiente a las x . El archivo con los atributos (x) está codificado en formato *sparse* de *matrix market* [5] como sigue. La cabecera del archivo pueden aparecer 0, 1 o más comentarios (filas que inician con %). La línea siguiente indica el número de filas, columnas y entradas no nulas de la matriz. Las líneas que siguen tienen la estructura (i, j, X_{ij}) , es decir indican la fila y columna de la matriz que contiene el tercer elemento. Por ejemplo:

```

1 %%MatrixMarket matrix coordinate real general
2 317 145256 658516
3 1 9 14.0
4 1 12 1.0

```

- (a) Lea los archivos de datos y cárguelos en dos dataframe o matrices X, y . En el caso de X es extremadamente importante que mantenga el formato disperso (sparse) (¿porqué?). Si trabaja con matrices use matrices dispersas del tipo *csr_matrix* o *csc_matrix*. Si prefiere operar sobre un dataframe, puede utilizar los (recientemente introducidos) dataframe dispersos de pandas: *SparseDataFrame*, aunque todavía no se tiene una operabilidad completa.

```
1 import pandas as pd
2 import numpy as np
3 from scipy.sparse import csr_matrix
4 from scipy.io import mmread
5 X = csr_matrix(mmread('test.x.nm'))
6 y = np.loadtxt('test.y.dat')
```

- (b) Construya un modelo lineal que obtenga un coeficiente de determinación (sobre el conjunto de pruebas) de al menos 0.75. A partir de un modelo lineal de *sklearn*, el coeficiente de determinación se obtiene fácilmente

```
1 import sklearn.linear_model as lm
2 model = lm.LinearRegression(fit_intercept = False)
3 print "R2=%f"%model.score(X, y)
```

References

- [1] <https://www.kaggle.com/harlfoxem/housesalesprediction>
- [2] Hastie, T.; Tibshirani, R., Friedman, J. (2009), The Elements of Statistical Learning, Second Edition. Springer New York Inc.
- [3] Joshi, M., Das, D., Gimpel, K., Smith, N. A. (2010). Movie reviews and revenues: An experiment in text regression. In the 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics (pp. 293-296). Association for Computational Linguistics.
- [4] <https://www.dropbox.com/sh/8r1wrbyfokwuq0/AABUEvgcuMxyZht2-KYyBptUa?dl=0>
- [5] <http://math.nist.gov/MatrixMarket/formats.html>